

RINGKASAN EKSEKUTIF: RISET PASAR & PREDIKSI RESPONS KAMPANYE

Memahami Perilaku Konsumen, Memilih Model Machine Learning yang Tepat, dan Melipatgandakan Untung dari Promosi

Mata Kuliah: Predictive Analytics	Domain: Riset Pasar (Market Research)	NIM / ID: 24130500004	Penyusun: RANDI RANATA
---	---	---------------------------------	----------------------------------

1. Kenapa Riset Ini Penting

Kampanye pemasaran langsung di industri ritel sekarang menghadapi dua masalah sekaligus: biaya komunikasi ke konsumen yang terus naik, dan konsumen yang makin bosan dibanjiri promosi. Kalau promosi disebar ke semua orang tanpa pilah-pilah, hasilnya sering rugi. Uang yang keluar untuk cetak katalog, ongkos kirim, atau biaya telepon ke konsumen yang sebenarnya tidak tertarik, hilang begitu saja tanpa ada penjualan yang masuk.

Di sinilah riset pasar berperan. Daripada menyebar promosi secara acak, perusahaan bisa memakai model prediksi untuk menebak siapa yang kemungkinan besar akan merespons tawaran. Dengan mengenali ciri-ciri konsumen berdaya beli tinggi dan menentukan batas keputusan yang tepat, tim pemasaran bisa memangkas pemborosan anggaran, menaikkan jumlah pembeli, dan memperbesar keuntungan bersih dari kampanye.

2. Data yang Dipakai dan Persiapannya

Riset ini memakai dataset Customer Personality Analysis, dataset riset pasar yang cukup dikenal (dipublikasikan oleh tim Analitika CRM iFood, dan diunggah ke Kaggle oleh Dr. Omar Romero-Hernandez dan Akash Patel). Dataset ini berisi data 2.240 konsumen ritel dengan 29 atribut, mencakup profil demografi, pola belanja dua tahun terakhir di enam kategori produk (anggur, daging, buah, ikan, makanan manis, dan produk premium), seberapa sering mereka bertransaksi lewat berbagai kanal, serta riwayat respons terhadap lima kampanye sebelumnya.

Variabel yang ingin diprediksi adalah Response, yaitu apakah konsumen menerima tawaran promosi atau tidak. Dari seluruh data, hanya 14,94% yang menerima tawaran, sisanya 85,06% menolak. Datanya memang tidak seimbang, tapi ini justru mencerminkan kondisi nyata di lapangan.

Sebelum dipakai, data ini dicek dulu kualitasnya. Ditemukan 24 data kosong di kolom Income (sekitar 1,07%), tiga data tahun lahir yang tidak masuk akal (1893, 1899, 1900, yang berarti usianya lebih dari 115 tahun), dan satu nilai Income yang sangat ekstrem sebesar \$666.666, jauh di atas nilai wajar (persentil ke-99 saja hanya \$94.000). Data-data aneh ini dibersihkan, dan nilai Income yang kosong diisi memakai nilai tengah (median) berdasarkan tingkat pendidikan orangnya. Isian status pernikahan yang tidak baku seperti 'YOLO', 'Absurd', dan 'Alone' digabung jadi 'Single'. Kolom yang nilainya sama semua (Z_CostContact, Z_Revenue) dan kolom ID dihapus supaya tidak mengganggu proses analisis.

3. Cara Membandingkan Model

Supaya hasilnya benar-benar bisa dipercaya dan tidak ada kebocoran data ke proses pelatihan (lihat penjelasan di bagian 7), semua proses pengolahan fitur, seperti StandardScaler untuk data angka dan OneHotEncoder untuk data kategori, dikemas dalam satu Pipeline scikit-learn yang hanya dilatih memakai data latih saja. Data dibagi menjadi 80% untuk latihan (1.788 baris) dan 20% untuk data uji yang benar-benar terpisah (448 baris), dengan proporsi kelas yang dijaga tetap seimbang di kedua bagian.

Lima model dibandingkan lewat proses validasi 5-Fold Cross-Validation:

- Baseline 1 (model dummy):** selalu menebak “tidak ada yang merespons”. Model ini dipakai untuk menunjukkan kalau akurasi 85% saja tidak berarti apa-apa secara bisnis.
- Baseline 2 (Regresi Logistik sederhana):** tanpa penyesuaian bobot kelas, dipakai sebagai patokan performa minimum.
- Kandidat 1 (Regresi Logistik tertala):** memakai penalti L2 dan bobot kelas yang diseimbangkan untuk mengatasi data yang tidak seimbang.
- Kandidat 2 (Random Forest):** kumpulan 250 pohon keputusan, dengan kedalaman dibatasi dan bobot kelas diseimbangkan.
- Kandidat 3 (Gradient Boosting):** 140 pohon yang dibangun bertahap untuk memperbaiki kesalahan model sebelumnya (learning rate 0,06, subsample 0,85).

4. Hasil Perbandingan Model

Dalam kampanye pemasaran langsung, dua ukuran yang paling penting dilihat adalah ROC-AUC dan PR-AUC, bukan sekadar akurasi. Alasannya, biaya kesalahan di sini tidak seimbang: kalau model gagal menangkap konsumen yang sebenarnya berminat membeli, potensi keuntungan sekitar \$45 per orang hilang begitu saja. Sebaliknya, kalau model salah menghubungi konsumen yang ternyata tidak berminat, biayanya cuma sekitar \$3. Karena 85% data didominasi konsumen yang menolak, angka akurasi mentah jadi gampang menyesatkan kalau dipakai sendirian.

Model	CV ROC-AUC	Holdout ROC-AUC	Holdout PR-AUC	Presisi	Recall
Dummy Baseline (Mayoritas)	0,5000	0,5000	0,1496	0,00%	0,00%
Regresi Logistik Sederhana	0,9086	0,8909	0,6179	71,43%	44,78%
Regresi Logistik Tertala (Balanced)	0,9090	0,8932	0,6259	44,55%	73,13%
Random Forest (Balanced)	0,8924	0,8846	0,5983	49,45%	67,16%
Gradient Boosting (Ensemble)	0,9127	0,9031	0,6525	80,00%	41,79%


5. Model Terbaik dan Penentuan Batas Keputusan

Dari lima model yang diuji, Gradient Boosting terpilih sebagai model utama karena hasilnya paling baik di data uji: ROC-AUC 0,9031 (di atas 0,90), PR-AUC 0,6525, dan presisi 80% pada batas keputusan standar.

Biasanya, model machine learning memakai batas keputusan 0,50 secara default, artinya kalau probabilitas prediksi di atas 0,50, konsumen dianggap akan merespons. Tapi dalam pemasaran langsung, biaya menghubungi konsumen sangat murah (\$3) dibanding potensi untung dari yang benar-benar membeli (\$45). Kalau tetap memakai batas 0,50, model jadi terlalu pelit: hanya menangkap 41,8% pembeli, dengan keuntungan bersih \$1.155.

Setelah dihitung ulang berdasarkan kurva keuntungan yang sebenarnya, batas keputusan yang paling optimal ternyata jauh lebih rendah, yaitu 0,09. Pada batas ini, kampanye berhasil menjangkau lebih dari 85% pembeli, dan keuntungan bersihnya naik jadi \$2.289, hampir dua kali lipat (+98,2%) dibanding kalau memakai batas default.

Kalau perusahaan lebih mengutamakan keseimbangan antara presisi dan recall, batas 0,14 adalah titik terbaik, dengan skor F1 sebesar 0,6022.



Gambar 1: Kurva Optimasi Keuntungan Bersih Kampanye Pemasaran (\$) dan Perbandingan Antar-Metrik

6. Rekomendasi yang Bisa Langsung Dijalankan

Analisis Permutation Importance dan Tree MDI menunjukkan bahwa faktor paling berpengaruh terhadap respons konsumen adalah Recency (berapa lama sejak transaksi terakhir), lama menjadi pelanggan, status pernikahan, riwayat merespons kampanye sebelumnya, serta belanja di kategori bernilai tinggi seperti daging dan anggur. Dari temuan ini, ada beberapa langkah yang bisa langsung diambil:

- 1. Fokuskan kampanye pada konsumen yang baru saja bertransaksi.** Konsumen yang bertransaksi dalam 45 hari terakhir punya tingkat respons empat kali lebih tinggi dibanding yang lain. Sebaiknya, 60% anggaran promosi dialokasikan khusus untuk kelompok dengan Recency $\leq$ 45 hari ini, dibanding menyebar katalog ke semua orang.
- 2. Buat pesan khusus untuk konsumen lajang.** Konsumen lajang punya tingkat respons 21,4%, sementara pasangan menikah hanya 11,6%. Materi promosi untuk segmen ini bisa difokuskan pada tema kepraktisan dan porsi untuk satu orang.
- 3. Bangun program VIP untuk konsumen yang pernah merespons promosi.** Konsumen yang pernah merespons minimal satu kampanye sebelumnya punya tingkat konversi 54,9%. Kelompok ini layak diberi akses eksklusif atau preview produk lebih dulu, karena secara konsisten memberi hasil dengan margin tinggi.

4. Gunakan batas keputusan 0,09, bukan 0,50, dalam operasional kampanye sehari-hari. Dengan batas ini, keuntungan bersih kampanye naik dari \$1.155 menjadi \$2.289, karena memanfaatkan selisih besar antara margin keuntungan dan biaya kontak yang murah.

7. Batasan Penelitian dan Langkah Selanjutnya

Ada beberapa batasan yang perlu diperhatikan. Pertama, hasil feature importance ini menunjukkan hubungan atau korelasi, bukan sebab-akibat. Jadi belum tentu memberi diskon akan langsung mengubah kebiasaan belanja konsumen, ini masih perlu dibuktikan lagi lewat uji A/B yang terkontrol.

Kedua, data yang dipakai adalah data historis yang sifatnya statis, semacam potret di satu waktu tertentu. Data ini belum mencakup interaksi konsumen secara real-time di aplikasi, pergerakan diskon dari kompetitor, atau perubahan harga bahan pangan.

Ke depannya, penelitian ini bisa dikembangkan dengan pendekatan Uplift Modeling (Causal Machine Learning), untuk membedakan konsumen yang benar-benar butuh diskon supaya mau membeli ('Persuadables') dari konsumen yang memang akan tetap membeli meski tanpa diskon ('Sure Things'). Ini penting supaya perusahaan tidak memberi diskon ke orang yang sebenarnya sudah pasti akan beli, sehingga margin keuntungan tidak tergerus percuma.